FITWMAMS　研究方案

基于事实保持交互世界模型的自动驾驶策略特异长尾测试与修复

Policy-Specific Long-Tail Testing and Repair of Autonomous Driving with Factual-Preserving Interactive World Models

研究构想、技术动机与技术路线

核心主线
自然驾驶关键事件识别 ⟶ 高保真交互世界构建 ⟶ 策略特异失效区域搜索 ⟶ 学习型驾驶策略修复 ⟶ 未见场景与外部轨迹泛化。

摘要

面向自动驾驶系统的长尾测试不仅需要发现危险场景，还需要使测试结果转化为可迁移的策略能力提升。针对自然驾驶事件回放缺乏策略响应、轨迹保真与自主交互难以协调，以及高风险搜索容易集中于少数重复失效的问题，本方案提出一种基于事实保持交互世界模型的策略特异长尾测试与修复框架。首先，利用极值理论自适应识别自然驾驶数据中的关键事件，为测试提供事实依据；其次，复用 Flow–Diffusion–HiQR 分层模型，通过动态交互关系、选择性控制权切换、纵横向机动决策与参考进度调整，使相关背景车辆能够响应被测系统，同时保持未受影响车辆的运动特征；再次，在显式行为随机空间中开展交互引导和多样性保持的自适应多层搜索，定位失效区域及其成功—失败边界；最后，采用成熟的学习型驾驶算法进行定向修复，并在未见事件、替代交通机制及外部轨迹来源上评价安全、效率与能力保持。研究重点在于失效发现效率、测试数据的修复价值及其泛化收益，概率估计作为固定仿真设置下的辅助统计保留。

关键词：自动驾驶；交通世界模型；极值理论；交互响应；失效区域；测试与修复

版本：研究设计 v1.0　更新日期：2026 年 9 月 26 日
代码依据：SafeDL/FITWMAMS，提交 `430f1622b716`
配套交付：12 项独立 Markdown 改进任务及实施索引

目录

1 研究定位与问题定义 3

2 技术动机与研究问题 4

3 现有技术基础与增量改进重点 5

4 总体技术路线 6

5 拟形成的创新点与方法差异 10

6 实验设计与评价指标 11

7 实施路线与任务分解 13

8 论文组织与预期研究结论 14

参考文献与代码依据 15

文档定位

本方案按照当前确认的“测试—修复—泛化”主线整理。已有代码能力与仓库报告构成实施基础；选择性可学习响应、MOBIL 扩展和结构化失效搜索为本轮拟议增强，其收益由后续实验检验。文中已有数值均注明来源，不作为新增机制的已完成结果。

正文侧重论文级研究问题与技术机制；配套任务文档给出具体代码位置、试验配置、验收方式和交付物。旧材料中以自然驾驶风险概率估计为中心的定位，在本轮调整为辅助分析。

1 研究定位与问题定义

1.1 从风险概率估计转向具有修复价值的长尾测试

本研究以自然驾驶事件为起点，以可执行的闭环交通交互为测试载体，以被测策略的失效发现及其修复收益为最终目标。极值理论用于从大量自然驾驶片段中自适应选择关键事件，交通世界模型用于将事件转化为能够响应外部自动驾驶系统的测试环境，多层搜索用于提高有限预算下的失效发现效率，学习型驾驶算法则用于检验测试结果能否转化为可迁移的能力提升。

这一定位并不要求首先建立仿真失效概率与真实道路风险的一一对应关系。研究证据由三个层次组成：事实轨迹重建与运动统计支持事件保真；干预与多主体实验支持响应机制有效；独立场景中的修复和泛化收益支持测试环境的应用效用。三者共同服务于“测试是否能够暴露并修复策略弱点”，而不是将单一碰撞率或轨迹误差作为全部论证。

现有资料已经提出将失效发现与概率估计区分处理, 并保留可重放的世界分叉机制 [1]。本轮在此基础上明确采用失效发现作为主任务：搜索可以向高风险、多样化和有修复价值的区域倾斜；原始子集模拟保留为对照及可选统计工具，不将偏置搜索的层比例乘积解释为自然道路事故率。

1.2 测试对象与闭环过程

设自然驾驶事件为 $e = (\mathcal{M}, C_0, H_0, \bar{\tau})$，其中 $\mathcal{M}$ 表示道路及参与者信息，C_0 表示初始状态，H_0 表示可用历史，$\bar{\tau}$ 表示事件参考轨迹。令 ω 为运动实现、驾驶风格与动态响应的外生随机变量，π_φ 为参数为 φ 的被测驾驶策略。闭环测试轨迹写为

$$\tau = \mathcal{S}_\theta(e, \omega; \pi_\varphi), \tag{1}$$

其中 θ 包含冻结的世界模型与 NPC 行为参数模型。初始阶段以 highD 高速局部片段和结构化状态输入为主要任务域，车辆控制继续采用现有 HighwayEnv 执行链。

对固定策略，令 $C(\tau)$ 表示预先定义的失效判据，例如碰撞、越界或任务失败，则事件对应的策略特异失效区域为

$$\mathcal{F}_\varphi(e) = \{\omega : C(\mathcal{S}_\theta(e, \omega; \pi_\varphi)) = 1\}. \tag{2}$$

搜索目标是在预算 B 内获得覆盖不同交互模式、能够重放并具有学习价值的失效档案 $\mathcal{A}_B$。所谓“区域”是通过邻域探索和行为描述覆盖得到的局部经验表征，不要求穷尽整个连续世界空间。

1.3 测试价值的评价目标

对测试档案进行修复得到 $\pi_{\varphi'}$。修复价值在独立评价集 $\mathcal{D}_{\text{eval}}$ 上比较，而不直接由挖掘样本上的训练收益定义。令 J 为包含安全、行驶进度和任务表现的评价函数，则

$$G_{\text{eval}} = J_{\mathcal{D}_{\text{eval}}}(\pi_{\varphi'}) - J_{\mathcal{D}_{\text{eval}}}(\pi_{\varphi}). \tag{3}$$

实际实验分别报告这些指标，避免将不同能力压缩成一个难以解释的加权分数。研究目标是提高有效失效发现和修复收益，并减少新增回归；不以无条件减少一切碰撞或强制所有 NPC 礼让为背景模型优化目标。

2 技术动机与研究问题

2.1 自然事件提供事实依据，但不能直接替代交互测试

自然驾驶轨迹记录了特定交通参与者共同作用下的一次运动实现。替换被测车辆策略后，车辆间距离、速度关系和车道占用可能改变。机械回放能够保持记录本身，却难以表达背景车辆对新交通状态的反应。因此，关键事件的测试价值不仅取决于其原始风险，还取决于能否在保留事件结构的同时产生合理的交互后续。

数据驱动仿真已经在联合行为生成与闭环演化方面取得进展。SceneDiffuser 将场景初始化与场景展开统一建模，VBD 支持多主体交互及推理期行为引导 [2, 3]。这些研究构成本文复用生成式运动先验的技术基础。本文进一步关注真实关键事件的保持、局部响应控制权与策略特异测试价值，而不是另行建设覆盖所有交通形态的大型生成模型。

2.2 高精度轨迹跟踪与自主响应存在控制冲突

高保真轨迹通常以时间为索引，隐含要求车辆在指定时刻到达指定位置。当 ADS 制动、切入或持续占道后，NPC 的合理动作可能是减速、等待、调整换道时序或改变目标车道。若仍要求严格追踪原时间计划，响应控制器就可能与基础解码器相互抵消。

已有代码报告中的动作分解表明，部分强制制动场景中，HiQR 的正向追赶动作需要由在线修正层施加更强负向修正抵消 [8]。这一现象直接支持如下研究问题：如何决定哪些 NPC 需要偏离原计划、何时转移控制权，以及如何在扰动解除后恢复高保真运动。已有空间路径插值、机动承诺和在线 MA-IDM 可作为基础，通过统一进度与机动状态形成更有解释力的机制。

2.3 危险程度不能单独代表测试信息量

风险排序与精英复制可以提高失效命中率，但容易使搜索集中于少数同源事件和相似碰撞。同一种缺陷被反复触发，未必提供更多修复信息。STRIVE 强调所生成危险场景应对规划器改进具有用途；CAT 将针对当前驾驶策略的危险场景生成与闭环训练结合；PLR 则

依据当前策略的学习潜力调整训练场景选择 [4, 5, 6]。

由此，本研究不仅关注“是否找到失败”，还关注失败由哪些交互机制产生、与已发现失败是否不同，以及失败邻域是否包含可学习的规避行为。将交互相关变异、多样性保持和失败边界定位结合，是区别于直接套用子集模拟的主要切入点。

2.4 修复收益需要通过独立能力验证

在挖掘场景中降低失败率，可以反映针对性适应，但不足以单独衡量迁移价值。更具解释力的实验是：从相同初始策略出发，使用不同来源的测试数据、相同修复规则及训练预算，再在未见事件、常规交通和外部轨迹来源上比较结果。

这一设计将测试方法和策略优化区分开。本文采用成熟的 DQN/PPO 作为可学习被测对象，避免同时引入新的策略网络、持续学习约束和复杂奖励。方法创新聚焦于测试世界及搜索机制，修复作为验证测试数据价值的闭环实验。

3 现有技术基础与增量改进重点

3.1 可以直接保留的系统能力

当前主链为 Flow → Diffusion → HiQR → 在线 MA-IDM NPC 响应 → HighwayEnv。世界创建接口已接入在线控制器，系统支持条件事实重建、已实现状态驱动的逐帧响应、既定换道修复、自主避险换道及显式世界随机状态 [7, 8]。本轮保留这些内容，仅增强关键接口和行为机制。

表 1: 当前结果基础与本轮研究用途

能力	已有报告或实现	本轮用途
条件事实重建	10,151 条 Test 的 ADE/FDE 为 0.035606/0.027590 m	作为保真基线，不再主要追求更低均值
左换道交互	同 ADS 动作下，几何重叠场景由 417 减至 84	支持响应层具有实际行为效果
右换道交互	重叠场景为 465 至 449；目标后车制动方向率 51.5%	优先改进方向逻辑与响应覆盖
纵向与次级响应	已有多档制动、加速及 NPC→NPC 实验	复用为规则与学习切换训练/诊断
参考与分叉	已有空间进度、参考追加及快照恢复接口	支持机动生命周期与局部搜索
稀有事件代码	已有完整世界随机空间的子集模拟与 pCN 提议	保留骨架，增加失效发现机制

数据来源为提交 430f1622…的仓库文档 [8, 9]，本次未重新运行。重建使用未来条件约束；左右干预队列并非相同样本，不能直接据两组比例估计方向偏差。

3.2 需要优先处理的真实瓶颈

第一，模型地图与道路执行器需要共享几何来源。当前控制器接收模型地图，而 HighwayEnv 桥接层按初始 ego 横向位置和固定宽度构造道路。接入原生换道查询和学习型 ADS 前，应统一车道中心、邻接关系、边界及逐车尺寸 [10]。

第二，部分响应规则依赖特定方向和主体身份。应将单侧切入通过逻辑改为相对于源/目标车道的有符号几何计算，将追赶抑制等条件从车辆编号转向实际交互关系，并保持同步状态—动作更新。

第三，已有自主新换道主要由急刹与预测间隙不足触发。应复用 IDM/MOBIL 评价持续慢车、路径阻塞和相邻车道机会；同时分离目标车道承诺、机动完成、参考重定位和控制权释放。

第四，现有驾驶员参数与动态响应创新的随机映射需要更易于分块搜索。独立驾驶参数和机动变量应具有可解释的变化方向，支持 actor/block 局部变异；原有重放能力继续保留。

第五，测试对象需要从固定干预或规则控制器扩展到可继续学习的 ADS。训练包装、语义动作、时间截断和固定评价事件是实现首轮修复的直接工作，不应等待全部行为增强完成后才开展。

4 总体技术路线

4.1 方法结构与信息流

本研究采用“事件识别—世界构建—失效搜索—策略修复—独立验证”的五阶段框架。世界模型与学习型 ADS 相互解耦：世界只依据已实现交通状态驱动 NPC，ADS 从可观测局部状态选择动作；搜索模块通过世界行为变量改变测试实例，不直接伪造车辆未来状态。

表 2: 各阶段输入、输出与核心职责

阶段	输入与输出	核心职责
事件识别	自然轨迹 → 关键种子与常规事件库	EVT 自适应选择、事件身份与数据分组
世界构建	事件/采样条件 → 可执行多车闭环	保真默认动作与选择性自主响应
失效搜索	冻结 ADS 与世界 → 失效档案及边界邻域	交互相关变异、多样性与预算分配
策略修复	失效/常规/历史场景 → 更新后的 ADS	成熟学习算法、同预算定向续训
独立验证	冻结策略 → 能力改善与回归统计	未见事件、替代机制、外部轨迹迁移

4.2 基于 EVT 的自然驾驶关键事件识别

延续现有安全包络侵入风险 R_{SEI}，将事件的峰值侵入与累计暴露结合：

$$R_{\mathrm{SEI}}(\tau) = \max_t \Phi_{\mathrm{raw}}(t) + \lambda_{\mathrm{exp}} \Delta t \sum_t \Phi_{\mathrm{raw}}(t). \tag{4}$$

其中风险计算、采样频率和窗口定义沿用当前上游流程 [11]。POT-GPD 用于刻画超阈值尾部，拟合阈值 u_{POT} 与测试事件选择水平 r_{sel} 分别确定。关键事件集合为

$$\mathcal{E}_{\mathrm{key}} = \{e : R_{\mathrm{SEI}}(\bar{\tau}_e) \geq r_{\mathrm{sel}}\}. \tag{5}$$

EVT 的作用是使关键事件选择随数据风险尾部自适应，而不是直接预测被测 ADS 的失效。连续风险分数服务于搜索排序，最终碰撞、越界和任务结果单独记录。

事件库同时保留常规样本和关键样本。Flow、Diffusion 与 HiQR 继续复用已有模型，不因测试聚焦尾部就将训练数据全部改为危险事件。每个事件具有稳定 ID，其变异分支继承源事件身份；同一交互的重叠窗口和多视角片段采用分组管理，避免训练与最终验证包含高度重合的实例。

EVT 与经验高风险筛选的比较应使用相同事件预算。对于同一标量风险的单调变换，选择同样 top-k 可能获得相同集合；因此 EVT 的统计价值由阈值适配、稳定性和来源覆盖体现，后续测试价值由实际挖掘与修复实验衡量。

4.3 事实保持的分层交互世界

Flow 负责宏观交通条件与可扩展场景采样，Diffusion 提供受条件约束的多车软计划，HiQR 提供逐帧高精度基础动作。针对真实事件的主实验可以采用事件锚定条件；自由生成模式用于扩展覆盖和条件变异。两类模式均进入同一在线交互与物理执行链。

设 NPC i 的基础动作为 $a^i_{\mathrm{base},t}$，其响应候选由局部交通状态和驾驶参数生成。所有车辆每帧都有动作，“选择性响应”特指选择哪些车辆需要偏离基础动作。动态交互关系应覆盖当前前车、潜在切入车辆、目标车道前后车和次级传播主体，并随已实现几何关系更新。

在纵向控制中，可采用如下统一表达：

$$a^i_{x,t} = \Pi_{\mathcal{A}_i}\left[(1-g^i_t)a^i_{\mathrm{base},x,t} + g^i_t a^i_{\mathrm{resp},x,t}\right], \qquad g^i_t \in [0,1], \tag{6}$$

其中 g^i_t 表示响应控制权，$\Pi_{\mathcal{A}_i}$ 表示共同的动作与变化率约束。该式描述本轮拟议的控制合成机制；现有基于规则的动作修正作为实现起点和对照。

横向机动先在保持、左变道、右变道等类别中选择，再由相应控制器执行，不能通过平均左右转向动作决定机动。未受影响且原计划可执行时，保留 HiQR 动作；受到局部交互影响时，允许纵向调整、延迟原机动或选择新机动。物理与时序约束服务于可执行性，不

要求背景交通主动消除被测策略造成的全部冲突。

4.4 机动生命周期与参考进度调整

将原计划分解为路径 $\bar{\mathbf{p}}_i(s)$ 与实际进度 s_t^i。在事实附近保持原时间索引；当扰动引起明显进度变化时，基于当前位置和运动状态查询空间参考。由此，NPC 可以保留车道目标和路径形态，而不被迫在原时间点到达原位置。

机动管理采用基础跟踪、局部响应、机动执行和参考重定位四个阶段。目标车道、进度、阶段持续时间和冷却时间独立保存。新换道完成后，先在目标车道建立与当前状态相容的参考，再释放响应控制权；后续存在新的交互需求时允许再次机动。

当前 150 个状态点对应 149 个真实转移，积分时长为 5.96 s。固定窗口结束与机动完成分开处理。对于晚启动机动，采用统一的补充恢复窗口和明确的尾段提供者；先复用已有参考追加接口，后续再评价滚动 Diffusion 重规划是否带来足够收益 [8]。基础版本不以重新训练长时模型为实施前提。

4.5 IDM/MOBIL 与轻量可学习切换

纵向响应继续使用观测标定的 IDM 系列参数。已有 Bayesian IDM 研究为驾驶员差异与行为不确定性的描述提供依据 [12]。本轮先保持现有参数结构，再通过分组或条件参数使横向倾向与纵向风格关联；驾驶参数在 episode 内保持持续性。

MOBIL 用于评价候选车道的运动收益及其对后车的影响 [13]：

$$\tilde{a}_n \geq -b_{\text{safe}}, \tag{7}$$

$$(\tilde{a}_i - a_i) + p\,[(\tilde{a}_n - a_n) + (\tilde{a}_o - a_o)] \geq \Delta a_{\text{th}}. \tag{8}$$

其中 n, o 分别为新旧车道后车，p 为礼让参数。原计划保持偏好、机动成本和冷却机制属于本项目的组合设计。MOBIL 评价机动，现有地图反馈控制完成横向动作，避免原生规则车辆直接覆盖整个 HiQR 行为链。

在规则增强有效后，增加轻量切换网络

$$(m_t^i, g_t^i) = G_\psi(H_t^{\text{local}}, \delta_t^{\text{plan}}, q_t^i, \theta_i), \tag{9}$$

其中 m_t^i 为基础跟踪、纵向响应或机动调整模式，δ_t^{plan} 为计划偏差，q_t^i 为机动状态。网络复用历史与关系特征，仅学习切换及控制权，不从零学习全部驾驶动作。

训练数据由事实保持样本、自然响应片段、已有干预实验和受控计划失配组成。观测标签与机制教师标签分别保存；训练冻结生成主干，仅优化小型 MLP 或必要的残差头。CAT-K 关于利用已有数据进行闭环监督微调的研究支持这种低训练成本的改进方向，但本项目的切换标签和控制权目标需独立设计 [14]。

近乎完美的事实计划会使切换网络退化为始终关闭，因此训练必须包含实际交互扰动和计划失配。模式输出配合迟滞与机动承诺，避免频繁接管和释放。学习版与规则版采用相同动作候选，才能区分切换学习和动作机制本身的贡献。

4.6 显式行为空间与交互引导多层搜索

复用现有世界外生随机变量表示，增加便于独立变异的驾驶员与机动块：

$$\omega = \left(z_{\text{scene}}, z_{\text{motion}}, z_{\text{driver}}, z_{\text{maneuver}}, \varepsilon_{1:T}\right). \tag{10}$$

该表达为语义分组，具体维度与现有模型接口对应。驾驶员参数与动态创新分离，支持在保持初始事件不变的情况下只改变某个主体的行为因素。对于联合解码器，局部 latent 变异可能通过交互影响其他主体，这是需要测量的行为后果，而不是要求所有非目标轨迹完全不变。

搜索保留现有子集模拟的粒子复制、风险分层和局部提议骨架 [9]，形成以下步骤。

1) 固定当前 ADS 与世界版本，从关键事件及少量探索事件初始化候选。
2) 执行闭环，记录连续风险、实际失败和交互描述；按当前候选的风险分位数确定下一层深挖门槛。
3) 根据动态影响关系和少量单块配对探针，将变异预算分配到相关 actor/block；保留全局提议以发现新模式。
4) 对高风险候选按交互描述分组，保留各组代表并限制同一祖先的复制比例，避免单一失效占据全部粒子。
5) 在选定变量上局部变异并重新执行；将有效不同失败归档，继续探索未覆盖的交互模式。
6) 对已发现失败搜索临界成功邻居，保存成功—失败邻接对与可供修复的决策前缀。
7) 修复后以新策略重放档案，更新未修复、新增和已解决失效的优先级，开展下一轮搜索。

首版采用完整事件重模拟。若后续引入前缀复用，需复制已实现状态、驾驶员参数、机动承诺、参考进度和模型隐藏状态；只刷新尚未使用的未来创新。改变已经影响前缀的参数时，应从事件起点重新运行，而不是把不相容后缀连接到旧前缀。

搜索同时优化危险性与信息量。危险性用于逐层深入，多样性用于避免模式集中，边界邻域用于提升诊断和修复价值。已有规避策略成功可以作为可学习性的证据；规避策略未成功不等于证明不可规避，所有有效失败仍应保留在测试档案。

4.7 学习型 ADS 与定向修复

采用 DQN 作为主要可修复策略，PPO 作为跨算法对照，IDM/MOBIL 作为非学习参考。SB3 提供标准实现，HighwayEnv 提供目标速度/车道层面的离散语义动作 [15, 16, 17]。本项目使用相同观察和动作语义比较不同学习方法，不把控制架构改变与测试数据收益混在一起。

观察使用 ego 状态、邻车相对运动、有效性和当前车道关系；不向 ADS 暴露 NPC 的未来计划及隐藏参数。世界保持 25 Hz，ADS 首版采用 5 Hz 决策，语义目标在多个物理子步内持续跟踪。低层控制仅实现目标跟踪，不隐式替代 ADS 进行避碰决策。

从基础策略 π_0 开始，每轮搜索得到 $\mathcal{A}_k$，再通过常规、新失效和历史修复场景混合训练得到 π_{k+1}：

$$\mathcal{D}_k^{\text{repair}} = \lambda_0 \mathcal{D}_{\text{normal}} + \lambda_1 \mathcal{D}_{\text{new},k} + \lambda_2 \mathcal{D}_{\text{history}}, \qquad \sum_j \lambda_j = 1. \tag{11}$$

该式表示采样混合。失败轨迹提供情境和决策窗口，而非正确动作监督标签；修复阶段从事件起点或相容前缀重新与世界交互。DQN 可以复用经验回放，PPO 通过当前策略重新采样训练轨迹。

一个修复系列中冻结 NPC 世界参数。不同世界版本的测试价值另行构成实验分组，以便将收益归因于 ADS 更新及测试数据来源。先完成一次修复验证，再增加两至三轮观察持续收益和遗忘，不以复杂持续学习算法为本研究的必要组成。

5 拟形成的创新点与方法差异

5.1 创新一：事实保持的选择性自主响应机制

将事实软计划视为可保持的运动依据，而不是不可改变的未来结果；通过动态交互关系确定响应主体，利用控制权切换协调基础解码与驾驶机制，以机动生命周期和参考进度调整消除固定时间计划与局部响应之间的冲突。创新重点是这些机制的协同及其可验证作用，而非单独使用 IDM、MOBIL 或残差网络。

5.2 创新二：交互引导、多样性保持的失效区域搜索

在现有多层搜索骨架上，将高风险分支选择从统一随机变异升级为 actor/block 相关性分配；以交互模式和祖先配额避免重复失效集中；以成功—失败边界定位提供更有诊断和学习价值的邻域样本。策略修复后更新搜索重点，形成针对当前 ADS 的动态测试过程。

5.3 验证闭环：测试效用与可迁移修复收益

使用成熟学习算法和等预算实验，将测试环境的轨迹/响应质量与后续策略收益连接起来。研究验证的不仅是场景生成质量，也包括测试数据对未见驾驶任务的净改善。修复更新本身作为实验机制，不额外包装为新的学习算法。

表 3: 与相关研究的定位关系

相关方向	可复用的基础	本文重点增强
SceneDiffuser / VBD	条件场景生成、交互与可控运动先验	真实关键事件的保持与选择性响应
IDM / MOBIL	可解释纵横向行为候选	计划冲突识别、控制权切换和进度调整
原始子集模拟	多层筛选、复制与局部提议	交互相关变异、多样性及修复边界
STRIVE / CAT	有用途的危险场景、针对策略的测试训练	事实保持世界中的结构化多层搜索
PLR	当前策略学习潜力驱动的场景复用	失效档案、边界邻域及修复反馈联动

6 实验设计与评价指标

6.1 研究问题与对照结构

实验围绕五个问题组织：关键事件选择是否提高测试起点的价值；选择性响应是否在保持事实特征的同时增强交互；结构化搜索是否以相同成本发现更多不同失效；测试数据是否带来高于常规训练的修复收益；收益是否迁移到未见事件与外部来源。

表 4: 主实验矩阵

问题	主要对照	主证据
RQ1	随机事件、经验高风险、EVT 自适应事件	来源覆盖、阈值稳定、等种子预算测试收益
RQ2	HiQR-only、当前响应、IDM/MOBIL 增强、学习切换	保真—响应权衡、幅度/时延、机动与传播
RQ3	随机搜索、原始子集模拟、结构化搜索逐项消融	独特失效、模式覆盖、边界对、预算曲线
RQ4	常规训练、EVT 事件修复、原始搜索修复、本文修复	配对净改善、回归、进度及持续收益
RQ5	未见 highD、替代 NPC、外部轨迹来源	冻结策略的跨场景相对收益

世界模型对照分为条件事实重建和闭环策略干预，不能将使用真实未来条件的 ADE 与仅使用历史的自由预测误差混排。对自由生成场景，使用非配对运动统计与执行质量，而非强行为随机样本指定唯一真实轨迹。

6.2 世界模型与响应指标

事实保持评价 ADE/FDE、事件误差尾部、风险过程误差和机动意图保持。响应评价采用相同事件和随机性下的动作效应，覆盖方向、幅度、时延、持续时间、恢复、目标车道完成及无关车辆改写。原始碰撞和逐车辆对接触记录保留，结合动作时序解释，不以碰撞净减少替代行为分析。

左右对称性通过配对几何变换隔离方向逻辑。对存在方向性驾驶规则的实验，应同步变换规则或在诊断单例中关闭该偏好，不能要求真实左右流量统计完全一致。主体替换测试保持同状态、同参数和同前车控制，检验不必要的编号依赖。

剂量响应在相同关系和机动条件下分析。更强制动可能触发新换道，后续平均纵向加速度不必与保持车道分支全时段严格排序。应同时报告原始与分层结果，而不是通过排除复杂机动获得表面完美指标。

6.3 失效发现效率与多样性

主指标为固定预算下的有效独特失效数、行为簇数量、首次有效失败时间、祖先集中程度及成功—失败边界对数量。所有方法采用相同事件、ADS、世界和失效定义。探针、无效候选、重放及边界搜索均计入总成本，同时报告仿真步数、完整世界调用量和实际耗时。

独特失效由预先确定的交互描述与距离规则识别，不以不同随机种子作为新模式的充分条件。数值发散或明显无效几何单独统计，不计入 ADS 行为失败，但其计算开销计入成本。辅助学习代理只有在确实减少昂贵执行时才加入，并与无代理版本比较。

6.4 修复净收益与能力保持

在相同评价事件与世界随机性下，对修复前后的策略形成四格结果。以 1/0 分别表示失败/成功，n_{ab} 记录修复前为 a、修复后为 b 的事件数，则

$$\text{RepairRate} = \frac{n_{10}}{n_{10} + n_{11}}, \qquad \text{RegressionRate} = \frac{n_{01}}{n_{00} + n_{01}}, \qquad \text{NetGain} = \frac{n_{10} - n_{01}}{N}. \quad (12)$$

分母无样本时标记不可计算。除失败率外，报告平均进度、速度、停滞、越界和动作平顺性，以排除通过不前进降低碰撞的退化策略。

各修复组从相同基础策略及训练状态启动，使用相同奖励、网络和更新规则。等训练步数实验衡量测试数据质量；等搜索加训练总成本实验衡量端到端效率，两者分开呈现。先开展单轮，继而增加多轮观察修复和遗忘，并在主结果上使用多随机种子。

6.5 跨场景与外部轨迹验证

第一层使用未参与挖掘、修复和调参的 highD recording/交互事件。历史上已经用于规则调试的 Test 案例保留为开发回归集，不删除其正向结果；新的独立评价来源用于检验后续增量。

第二层替换 NPC 行为机制，例如日志回放、HiQR-only 或原生 IDM/MOBIL，并首先保持 ADS 的低层动力学与动作语义一致。比较的是同一环境内修复前后的相对变化，不以不同环境的原始碰撞率判断谁更真实。

第三层采用其他轨迹数据来源。NGSIM US-101/I-80 可用于与高速任务兼容的外部事件，原始位置按 0.1 s 记录 [18]。转换时统一单位、坐标、车道和时间采样，再以冻结 ADS 权重评价。exiD 提供高速出入口及地图信息，可在统一道路拓扑接口后作为进一步扩展 [19]。外部数据如参与参数再标定，应将适配后结果与零样本迁移分开报告。

6.6 实验规模与增量决策

采用定向单例、小规模队列和完整独立评测三个层级。先用 20–50 个案例排查机制，再用约 200–500 个事件比较候选；选定配置后开展完整评价。学习与搜索先以一个种子检查有效性，主要结果再用三个及以上种子确认。置信区间按源事件或 recording 分组计算，避免同一祖先的多个分支被视为独立证据。

验收关注目标瓶颈的改善、已有关键能力的保持和额外计算成本。接口一致性任务不要求碰撞率改善；响应任务评价保真与交互的权衡；搜索任务评价等预算的独特失效；修复任务评价未见数据中的净收益。配套任务中的误差和比例目标均为首轮试验观察线，不是通用安全门槛或已取得结果。

7 实施路线与任务分解

7.1 阶段一：先打通学习型策略的正向闭环

并行整理 EVT 事件清单与统一指标，完成道路几何接口后接入 DQN。首先使用当前已经有效的响应世界和关键事件开展一次修复，验证可继续训练、固定事件评价和能力改善。这一步不等待 MOBIL、学习切换和改进搜索全部实现。

训练效率优先通过缓存初始化计划、复用当前 batch 推理和避免多进程重复装载 GPU 世界模型改善。记录重置、模型推理和物理推进成本，再针对瓶颈优化；不预先建设复杂并行平台。

7.2 阶段二：逐项增强自主响应

依次统一动态关系和方向逻辑，加入机动生命周期与参考进度管理，再扩展 IDM/MOBIL 候选选择。每一步与上一版本比较，保留已经有效的行为。规则增强形成稳定基线后，开展轻量可学习切换；没有明确收益时优先调整样本与目标，而不是扩大网络。

7.3 阶段三：形成测试方法创新与泛化证据

整理可解释随机块，接入交互引导多层搜索，依次增加多样性复制和边界定位。以同一基础 ADS 比较随机、原始子集模拟和本文搜索产生的数据价值。完成 DQN 主实验后增加 PPO，并将冻结策略迁移到替代交通机制及外部轨迹。

表 5: 配套独立改进任务与研究职责

编号	独立修改目标	主要职责
T01	统一场景几何与执行接口	统一模型地图、RoadNetwork、车辆尺寸
T02	动态交互关系与方向对称	统一响应主体、镜像与身份逻辑
T03	机动状态与参考进度	消除时间追赶，完成后重定位参考
T04	IDM/MOBIL 纵横向响应	扩展非急刹机动与持续驾驶风格
T05	轻量可学习响应切换	学习何时接管及控制权大小
T06	学习型 ADS 环境与基础训练	接入 DQN/PPO 及可继续训练策略
T07	EVT 关键事件库与数据划分	选择关键种子，管理事件与变异身份
T08	行为随机空间与分叉	支持 actor/block 局部可解释搜索
T09	交互引导多层失效搜索	风险深入、多样性和边界定位
T10	测试驱动修复与回归	等预算修复与迭代能力保持
T11	外部数据与泛化验证	未见事件、替代 NPC 与外部轨迹
T12	指标与增量验收	统一四层指标、分级试验与配对结果

8 论文组织与预期研究结论

论文建议依次设置引言、相关工作、问题定义、事实保持交互世界、结构化多层失效搜索、测试驱动修复实验、消融与泛化分析，以及结论。引言围绕真实事件可交互化、轨迹与响应协调、危险性与测试价值三项动机展开；方法部分突出两类实质机制，避免按所有软件目录逐项罗列贡献。

预期通过实验回答：选择性自主响应是否在保持已有重建能力的同时扩大有效交互范围；交互引导与多样性保持是否提升单位预算的不同失效发现；边界邻域是否比仅使用最严重失败更利于修复；由此得到的能力提升是否延伸到未见事件和外部数据。

研究方案不预设全部新增模块均有效。各模块以实际增量证据决定最终论文保留内容。已有 Flow–Diffusion–HiQR 与在线 MA-IDM 成果不因某个新网络或搜索变体无收益而失去价值；新方案的推进方式是从已有效系统出发逐项验证差异，而非重新建设全部框架。

凝练后的研究表述

本文面向自动驾驶策略的长尾弱点发现与修复，利用极值理论识别自然驾驶关键事件，以事实保持的选择性自主响应世界实现高保真闭环测试，并通过交互引导、多样性保持的多层搜索定位具有修复价值的失效区域，最终以学习型驾驶策略在未见场景及外部轨迹上的净改善验证测试效用。

参考文献与代码依据

[1] 项目研究备忘录. DriveZero 启发下的分层反事实世界模型长尾测试方案. 2026-09-11, 第 5 页. 用户提供文件：`insights+20260911.pdf`.

[2] JIANG C M, BAI Y, CORNMAN A, et al. SceneDiffuser: Efficient and Controllable Driving Simulation Initialization and Rollout. NeurIPS, 2024. arXiv:2412.12129.

[3] HUANG Z, ZHANG Z, VAIDYA A, et al. Versatile Behavior Diffusion for Generalized Traffic Agent Simulation. 2024. arXiv:2404.02524.

[4] REMPE D, PHILION J, GUIBAS L J, et al. Generating Useful Accident-Prone Driving Scenarios via a Learned Traffic Prior. CVPR, 2022. arXiv:2112.05077.

[5] ZHANG L, PENG Z, LI Q, ZHOU B. CAT: Closed-loop Adversarial Training for Safe End-to-End Driving. CoRL, 2023. arXiv:2310.12432.

[6] JIANG M, GREFENSTETTE E, ROCKTÄSCHEL T. Prioritized Level Replay. ICML, PMLR 139:4940–4950, 2021. 论文与补充材料.

[7] SafeDL. FITWMAMS：分层交通行为世界模型及在线控制实现. 提交 `430f1622b716`, 2026-09-26. 代码目录.

[8] SafeDL. Traffic_World_Model_Convergence.md. 同上提交. 当前行为与重建报告.

[9] SafeDL. IDM–AMS README 与 world_subset_simulation.py. 同上提交. 子集模拟代码；评测链说明.

[10] SafeDL. hierarchical_world_model/src/highway.py. 同上提交. HighwayEnv 桥接实现.

[11] SafeDL. highD 自然驾驶片段与 SEI EVT. 同上提交. 风险与事件处理说明.

[12] ZHANG C, SUN L. Bayesian Calibration of the Intelligent Driver Model. 2022, revised 2024. arXiv:2210.03571.

[13] KESTING A, TREIBER M, HELBING D. General Lane-Changing Model MOBIL for Car-Following Models. Transportation Research Record, 1999(1):86–94, 2007. DOI:10.3141/1999-10.

[14] ZHANG Z, KARKUS P, IGL M, et al. Closed-Loop Supervised Fine-Tuning of Tokenized Traffic Models. CVPR, 2025. arXiv:2412.05334.

[15] Stable-Baselines3. DQN Documentation. 访问日期：2026-09-26. 官方算法与接口说明.

[16] Stable-Baselines3. PPO Documentation. 访问日期：2026-09-26. 官方算法与接口说明.

[17] Farama Foundation. HighwayEnv: Actions; Behavior. 访问日期：2026-09-26. 语义动作；IDM/MOBIL 行为实现.

[18] Federal Highway Administration. Next Generation Simulation (NGSIM) Vehicle Trajectories and Supporting Data. 官方数据目录. 访问日期：2026-09-26.

[19] leveLXData. The exiD Dataset. 官方数据与地图说明. 访问日期：2026-09-26.